

Atividade predição

Considerando o conjunto de dados Boston (<http://lib.stat.cmu.edu/datasets/boston>), da biblioteca MASS no R, que registra informações coletadas pelo Census dos EUA a respeito de moradia na área de Boston. Vamos prever medv (média do valor de uma casa em 1,000 USD) usando os 13 atributos que descrevem os dados.

Para que possamos comparar os modelos obtidos, vamos deixar parte do conjunto para ser usado como validação – somente no item (d). Portanto, divida o conjunto em dois, um contendo 100 instâncias para ser usada como teste e o outro com 406, para usar como treino. Para os itens (a), (b) e (c) somente o conjunto de treino deve ser usado. Considere somente modelos lineares.

- (a) Use a função `regsubsets()` para encontrar o melhor conjunto de atributos. Qual é o melhor modelo de acordo com as medidas C_p , BIC, and R^2 ajustado? Mostre gráficos para dar suporte a sua resposta e mostre os coeficientes do melhor modelo.
- (b) Repita o procedimento em (a), usando seleção progressiva e seleção regressiva. Como sua resposta agora se compara aos resultados do item (a)?
- (c) Realize a seleção de variáveis e de modelos usando validação cruzada no conjunto de treino.
- (d) Compare os modelos obtidos nos itens (a), (b) e (c) no conjunto de teste. Qual deles é o melhor?

Entregar somente um relatório detalhando o que foi feito.